

lineare Regression

Überblick

1. Einsatzgebiet
2. Vorhersage über Methode der kleinsten Quadrate
3. Regressionsgleichung
4. Voraussetzungen
5. Güte der Vorhersage
 - Standardschätzfehler
 - Konfidenzintervall
6. Kreuzvalidierung
7. Regression zur Mitte

1. Sinn & Zweck

- Vorhersage einer Variable durch eine andere

- vorherzusagende Variable (y) =

- zur Vorhersage verwendete Variable (x) =

- Bsp: Vorhersage...

-

durch


-

durch

2. Vorhersage-Prinzip

- Ermittlung einer

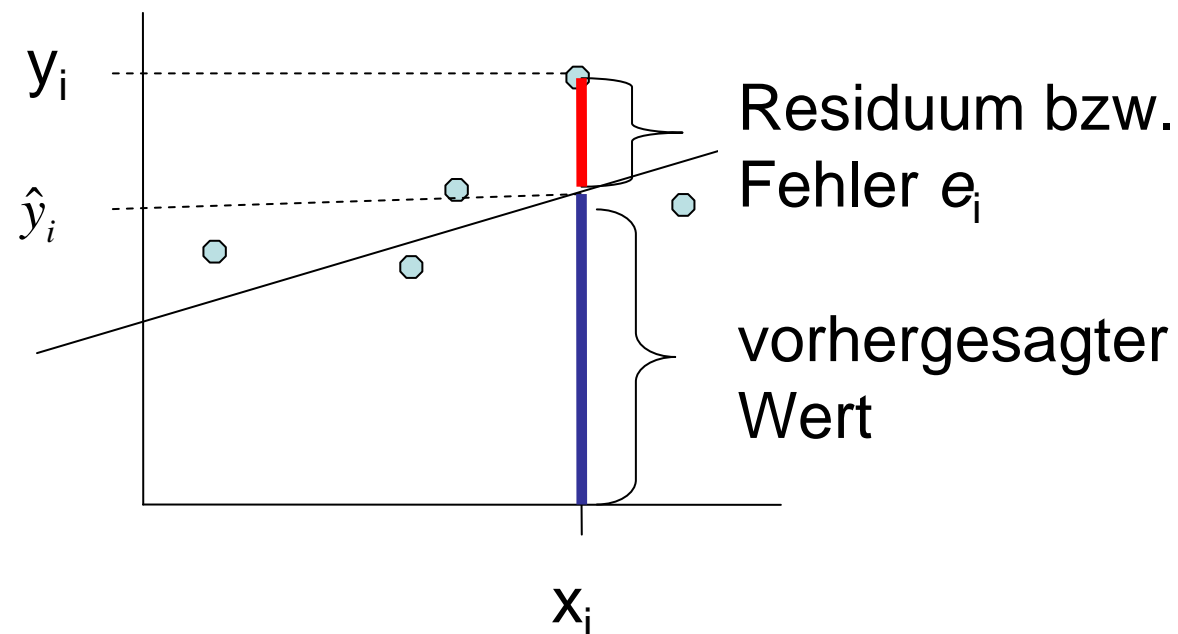
- nach der



Methode der kleinsten Quadrate

- Regressionsgerade wird so durch die Punktwolke gelegt, daß der quadrierte Vorhersagefehler über alle Probanden minimal ist:

$$\sum_{i=1}^N (y_i - \hat{y}_i)^2 = \min$$



3. Regressionsgleichung I


Regressionskoeffizient

Prädiktorwert

vorhergesagter Wert

$$\hat{y}_i = b_{y.x} \cdot x_i + a_{y.x}$$

Konstante



Beispiel

$$\hat{y}_i = 0.20 \cdot x_i + 1.00$$

Für Patientin mit einem **Depressionswert** von 20 soll der **Ängstlichkeitswert** geschätzt werden:

Regressionsgleichung II


vorhergesagter Wert \rightarrow

Prädiktorwert \downarrow

$$\hat{y}_i = r_{xy} \cdot \frac{s_y}{s_x} \cdot (x_i - \bar{x}) + \bar{y}$$

$$b_{yx} = r_{xy} \cdot \frac{s_y}{s_x}$$

$$a_{yx} = \bar{y} - b_{yx} \cdot \bar{x}$$



4. Voraussetzungen

1.

2.


3.

4.

5.

6.

5. Güte der Vorhersage: Standardschätzfehler



=

•

•

Standardschätzfehler: Formeln

- Stichprobe:

$$s_{y.x} = s_y \cdot \sqrt{1 - r_{xy}^2}$$

- Populationsschätzung:


$$\hat{\sigma}_{y.x} = \sqrt{\frac{N}{N-2}} \cdot s_{y.x}$$

- nimmt ab (Schätzung wird genauer!):

-
-
-

Konfidenzintervall

- = Bereich, in dem ein wahrer Wert mit einer bestimmten Wahrscheinlichkeit liegt.
- Bei normalverteilten Variablen liegen 95% aller Werte in einem Bereich von Mittelwert ± 1.96 Standardabweichungen.



Aus der z-Tabelle:

$$z(p=0.025) = -1.96$$

$$z(p=0.975) = 1.96$$

Konfidenzintervall


- Über den **Standardschätzfehler**, kann ein Konfidenzintervall berechnet werden, in dem mit bspw. 95%iger Wahrscheinlichkeit der wahre y-Wert liegt

- Stichprobe:

$$KI = \hat{y}_i \pm 1.96 \cdot s_{y.x}$$

- Populationsschätzung:

$$KI = \hat{y}_i \pm 1.96 \cdot \hat{\sigma}_{y.x}$$



6. Kreuzvalidierung: Überprüfung der externen Validität

(1) Berechnung der Regressionsgleichung R_1 anhand der Stichprobe S_1 .

(2) Anwendung der Regressionsgleichung R_1 auf die zweite Stichprobe S_2 .


(3) Vergleich der vorhergesagten Kriteriumswerte mit den wahren Kriteriumswerten in S_2 .

Berechnung der Regressionsgleichung R_2 anhand der Stichprobe S_2 .

Anwendung der Regressionsgleichung R_2 auf die Stichprobe S_1 .

Vergleich der vorhergesagten Kriteriumswerte mit den wahren Kriteriumswerten in S_1 .

7. Regression zur Mitte



- Problem, wenn bei wiederholter Messung die Personen der Stichprobe zu Beginn Extremwerte haben.
- Dann findet man statistisch einen Zusammenhang, der teilweise zufällig entstanden ist.

Übersicht über Abweichungen

- Varianz/
Standardabweichung

- Maß für Streuung individueller Werte

$$\hat{\sigma}_x^2 = \frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N-1}$$

- Standardfehler

- Maß für Streuung der Stichprobenkennwerteverteilung (Mittelwert, Median)
- Konfidenzintervall

$$\hat{\sigma}_{\bar{x}} = \sqrt{\frac{\hat{\sigma}_x^2}{N}} = \frac{\hat{\sigma}_x}{\sqrt{N}}$$

- Standardschätzfehler

- Maß für Streuung tatsächlicher y-Werte um Regressionsgerade
- Konfidenzintervall

$$\hat{\sigma}_{y.x} = \sqrt{\frac{n}{n-2}} \cdot s_{y.x}$$